

Analisis Differential Expression dari GSE315344

Respons Transkriptomik terhadap ZL0580 dan JQ1 dalam Sel J-Lat

Hendra Bunyamin

2026-07-28

Virus HIV dan Dua Cara Membasminya

Bayangkan virus *human immunodeficiency* (HIV) sebagai penjahat berbahaya yang telah menyusup ke dalam sebuah rumah, dalam hal ini, sel-sel tubuh. Biasanya, sistem kekebalan bertindak seperti pasukan keamanan yang waspada, yang mampu mendeteksi dan menyapukan penyerang semacam itu. Namun, HIV memiliki trik yang sangat licik: ia bisa masuk ke “*mode sembunyi*”. Setelah menginfeksi sel, virus ini menyisipkan instruksi genetiknya langsung ke dalam DNA sel inang, secara efektif menyimpan cetak birunya ke dalam perpustakaan pusat sel (baca: DNA) tersebut. Begitu berada di sana, virus ini menjadi sepenuhnya diam $\Rightarrow$ tidak memproduksi protein virus, tidak membuat salinan dirinya sendiri, dan tidak memicu alarm apa pun. Virus tersebut masih ada, bersembunyi di dalam genom, tetapi tetap tidak terlihat oleh sistem kekebalan tubuh maupun obat antivirus standar. Keadaan diam dan tidak aktif ini dikenal sebagai **laten virus**, dan hal ini merupakan tantangan terbesar dalam upaya memberantas HIV dari tubuh.

Para ilmuwan sedang berusaha menemukan obat untuk HIV, tetapi mereka tidak bisa begitu saja membasmi virus yang tersembunyi itu karena mereka tidak bisa menemukannya. Terdapat dua strategi utama untuk membasmi virus yang tersembunyi ini, yaitu:

- “*Shock and kill*” $\Rightarrow$ membangunkan virus agar sistem kekebalan tubuh atau obat-obatan dapat mendeteksinya dan menghancurkannya.
- “*Block and lock*” $\Rightarrow$ menjaga agar virus tetap tertidur selamanya, sehingga tidak akan pernah bangun lagi untuk menimbulkan masalah.

Latar Belakang Dataset GSE315344

Dataset yang digunakan dalam percobaan ini adalah [GSE315344](#) (Kumar et al. 2026). Dataset ini merupakan hasil penelitian dua obat berbeda yang memengaruhi HIV dengan cara yang berlawanan, yaitu:

- **JQ1** $\Rightarrow$ Obat ini berfungsi seperti “panggilan bangun” (*wake up call*). Obat ini memaksa HIV yang tersembunyi untuk mengaktifkan gen-gennya dan mulai membuat salinan dirinya sendiri. Hal ini berguna untuk strategi “*shock and kill*”.
- **ZL0580** $\Rightarrow$ Obat ini bekerja sebaliknya. Obat ini bertindak seperti “obat tidur”. Obat ini mendorong virus untuk tetap tertidur lelap dan membuatnya jauh lebih sulit bagi virus untuk bangun kembali. Hal ini berguna untuk strategi “*block and lock*”.

Berikut ini adalah apa yang dilakukan oleh para ilmuwan dalam percobaan ([GSE315344](#)) ini:

- Mereka mengambil jenis sel manusia spesifik mengandung HIV yang tersembunyi dan dalam keadaan tidak aktif ke dalam cawan laboratorium. Jenis sel ini disebut J-Lat.
- Mereka membagi sel-sel ini menjadi tiga kelompok:
 - Kelompok 1 diberi cairan yang tidak berbahaya (**DMSO**) $\Rightarrow$ ini adalah kelompok pembanding yang “tidak diberi perlakuan apa pun”.
 - Kelompok 2 diberi obat pengaktif (**JQ1**).
 - Kelompok 3 diberi obat penidur (**ZL0580**).

Setelah 24 jam, mereka menggunakan mesin berteknologi tinggi untuk membaca setiap gen aktif dalam sel-sel tersebut. Ini seperti memfoto “halaman” mana dalam buku petunjuk sel (DNA) yang sedang dibaca pada saat itu. Proses ini disebut sekuensing RNA (**RNA sequencing**).

Tujuan Proyek Mini ini

Tujuan proyek ini adalah menganalisis **RNA sequencing** pada dataset genomik dengan kode [GSE315344](#).

Metode yang Digunakan

Metode yang digunakan dalam proyek ini terdiri dari 4 (empat) langkah, yaitu:

1. *Data preparation* $\Rightarrow$
 - a. Source: GEO Dataset GSE315344
 - b. Model: jenis sel manusia spesifik mengandung HIV yang tersembunyi dan dalam keadaan tidak aktif (**J-Lat**)
 - c. Cohorts: 2x Control (DMSO) vs. 2x Treated (ZL0580) vs. 2x Treated (JQ1)
2. *Filtering & Normalization* $\Rightarrow$

- a. Environment: R
 - b. Engine: DESeq2 package
3. *Differential Gene Expression (DEG) Analysis* $\Rightarrow$
- a. Threshold 1: $|\log_2 \text{FC}| > 1$ (Minimum $3\times$ change)
 - b. Threshold 2: Adjusted p-value < 0.05
4. *Visualization* $\Rightarrow$
- a. Tools: ggplot2, pheatmap, dplyr

Analisis ini mencakup beberapa langkah (*mission*). Mari kita mulai langkah per langkah.

Mission 01: Data Preparation

Mari kita baca data *raw counts* dan kita simpan ke variabel `counts`.

```
library(readxl)
counts <- read_excel("GSE315344_raw_counts.xlsx")
counts <- as.data.frame(counts)
```

Kita tampilkan jumlah baris dan kolom dari `counts`.

```
rownames(counts) <- counts[[1]]
counts <- counts[,-1]
dim(counts)
```

```
[1] 25610      6
```

25610 menunjukkan jumlah gen yang ada dan 6 menunjukkan jumlah sampel yang ada. Kondisi sampel-sampel ini meliputi **2 DMSO**, **2 JQ1**, dan **ZL0580**.

Selanjutnya, mari kita buat metadata dari dataset ini.

```
sample_names <- colnames(counts)
sample_names
```

```
[1] "NC-1" "NC-2" "B48-1" "B48-2" "JQ1-1" "JQ1-2"
```

```
# Jumlah sampel kita adalah 6
condition <- c("DMSO", "DMSO", "ZL0580", "ZL0580", "JQ1", "JQ1" )

metadata <- data.frame(
  sample    = sample_names,
  condition = condition
)
rownames(metadata) <- sample_names
print(metadata)
```


	sample	condition
NC-1	NC-1	DMSO
NC-2	NC-2	DMSO
B48-1	B48-1	ZL0580
B48-2	B48-2	ZL0580
JQ1-1	JQ1-1	JQ1
JQ1-2	JQ1-2	JQ1

Pastikan bahwa nama-nama sampel dari `counts` dan `metadata` adalah sama.

```
colnames(counts) == rownames(metadata)
```

```
[1] TRUE TRUE TRUE TRUE TRUE TRUE
```

Kemudian kita akan mendistribusikan data-data ini dalam diagram *box plot*.



Mari kita coba filter gen dengan jumlah reads yang rendah dan bandingkan sebelum dan sesudah filter.

```
# 1. Filter: gen dengan total reads >= 10 di semua sampel
keep <- rowSums(counts) >= 10
counts_filtered <- counts[keep,]

# 2. Bandingkan jumlah gen sebelum dan sesudah filter
dim(counts)
```


```
[1] 25610      6
```

```
dim(counts_filtered)
```

```
[1] 17478      6
```

Terjadi pengurangan jumlah gen setelah difilter, yaitu dari 25610 menjadi 17478.

Selanjutnya kita coba hitung korelasi antar sampel.



Terlihat bahwa korelasi antara NC atau DMSO (sampel yang diberi cairan yang tidak berbahaya) dengan B48 atau ZL0580 cukup tinggi (0.97 dan 0.98). Demikian juga korelasi antara NC atau DMSO (sampel yang diberi cairan yang tidak berbahaya) dengan JQ1 cukup tinggi (0.94) sedangkan korelasi antara sampel pertama NC atau DMSO dengan sample kedua NC atau DMSO tinggi $\Rightarrow$ sedikit perbedaan antara DMSO dan ZL0580. Demikian juga, perbedaan DMSO dan JQ1 adalah sedikit. Selanjutnya, dendrogram di atas dan samping heatmap juga menampilkan pemisahan yang jelas antara kelompok treatment dan kelompok kontrol.

Selanjutnya, kita akan melakukan *Principal Component Analysis* (PCA). Terlebih dahulu, kita hitung *principal component* ke-1 dan ke-2.

```
# =====
#   Langkah 6: PCA
# =====
# 1. PCA dengan data yang sudah di-log (karena data counts sangat skewed)


row_var <- apply(counts_filtered, 1, var)
counts_filtered_variable <- counts_filtered[row_var > 0, ]

# Now apply log transformation and PCA
log_data <- log2(counts_filtered_variable + 1)
pca_result <- prcomp(t(log_data), scale = TRUE)
```

```
# 2. Buat data frame untuk plotting
pca_df <- data.frame(
  PC1 = pca_result$x[,1],
  PC2 = pca_result$x[,2],
  condition = metadata$condition
)
head(pca_df)
```

	PC1	PC2	condition
NC-1	-50.93806	67.638562	DMSO
NC-2	-53.02268	78.082577	DMSO
B48-1	-76.36717	-70.941871	ZL0580
B48-2	-78.41356	-57.097755	ZL0580
JQ1-1	127.28611	-3.594519	JQ1
JQ1-2	131.45536	-14.086993	JQ1

Kita plot *principal component* dari 6 sampel ini.



Terlihat bahwa ada perbedaan antara DMSO (kontrol) dengan ZL0580 (treatment ke-1) dan JQ1 (treatment ke-2) $\Rightarrow$ cluster treatment (ZL0580 dan JQ1) dan cluster kontrol (DMSO) berjauhan satu sama lain.

Mission 02: Normalization

Mari kita load library-nya.

```
# 1. Load library
library(DESeq2)
```

Selanjutnya, kita buat DESeq2 *object* (dari count matrix dan metadata).

```
# 2. Buat DESeq2 object (dari count matrix dan metadata)
dds <- DESeqDataSetFromMatrix(
  countData = counts,
  colData = metadata,
  design = ~condition
)
```

Kita lakukan normalisasi pada data dan simpan data hasil normalisasi yang selanjutnya akan digunakan untuk visualisasi.

```
# 3. Mulai normalisasi
dds <- DESeq(dds)


# 4. Ambil size factors (faktor normalisasi)
sizeFactors(dds)
```

	NC-1	NC-2	B48-1	B48-2	JQ1-1	JQ1-2
	1.0213013	0.9773316	1.0260651	0.9993739	1.0109884	1.0220221

```
# 5. Ambil data yang sudah dinormalisasi
# Data ini bisa kita gunakan untuk visualisasi (heatmap, PCA)
rld <- rlog(dds, blind = FALSE) # -> Jika dataset kecil, karena lebih lambat
vsd <- vst(dds, blind = FALSE)  # -> Jika dataset besar, karena lebih cepat
```

Kita visualisasi dataset dengan **Box Plot**.

Perbandingan Distribusi Ekspresi Gen Data Mentah vs. Data Normalisasi (rlog)



Setelah dataset dinormalisasi, bentuk *box plot* data menjadi semakin seragam $\Rightarrow$ proses normalisasi berhasil mengurangi variasi teknis antar sampel.

Mission 03: Differential Gene Expression (DEG) Analysis

Analisis DEG akan dibagi 2 (dua), yaitu

1. Analisis DEG untuk ZL0580 dan DMSO dan
2. Analisis DEG untuk JQ1 dan DMSO.

DEG Analysis antara ZL0580 dan DMSO

Mari kita hitung berapa jumlah gen yang naik dan turun setelah dikenakan obat **ZL0580**.

```
# 1. Membuat object dds
dds <- DESeqDataSetFromMatrix(
  countData = counts_filtered,
  colData = metadata,
  design = ~condition
)
```

```

# 2. Jalankan DESeq2
library(DESeq2)
dds <- DESeq(dds)

# 3. Ambil hasil perbandingan
res <- results(dds, contrast = c("condition", "ZL0580", "DMS0"))
res <- res[order(res$padj),TRUE]

# Selanjutnya, kita akan melakukan filter gen
# 1. Ubah data jadi format dataframe
res_df <- as.data.frame(res)

# 2. Tambahkan kolom status signifikansi
res_df$significant <- ifelse(
  !is.na(res_df$padj) &
  res_df$padj < 0.05 &
  abs(res_df$log2FoldChange) > 1,
  "Signifikan",
  "Tidak Signifikan"
)

# 3. Tambahkan kolom arah perubahan
res_df$direction <- ifelse(
  !is.na(res_df$padj) & res_df$padj < 0.05 & res_df$log2FoldChange > 1, "Naik",
  ifelse(
    !is.na(res_df$padj) & res_df$padj < 0.05 & res_df$log2FoldChange < -1,
    "Turun", "Tidak Signifikan"))

# 4. Filter gen signifikan
sig_genes <- res_df[res_df$significant == "Signifikan",]
nrow(sig_genes)

```

[1] 297

```

# 5. Lihat gen naik dan turun
table(sig_genes$direction)

```

```

Naik Turun
63    234

```

Total jumlah gen yang *differently expressed* adalah 297 yang menunjukkan bahwa ZL0580 mempunyai efek yang cukup luas bila dilihat dari jumlah gen-nya.

```
63 + 234
```

```
[1] 297
```

Kita *export* hasil sebelumnya ke suatu file *csv*.

```
# 1. Export hasil
write.csv(res_df, "DEG_results_GSE315344_ZL0580_vs_DMSO.csv")
```

Berikut ini adalah top 10 gen yang ekspresinya **naik**.

```
# 2. Lihat top 10 gen naik
top_up <- head(res_df[res_df$direction == "Naik",c("log2FoldChange", "pvalue",
                                                    "padj")], 10)
print(top_up)
```

	log2FoldChange	pvalue	padj
DNAJB1	2.210213	0.000000e+00	0.000000e+00
HMGCS1	2.020422	4.993676e-303	3.348509e-299
MSM01	1.868907	1.962718e-179	8.774004e-176
HMGCR	1.393609	9.729553e-150	3.262076e-146
HSPA1B	3.950887	1.107547e-128	2.970662e-125
LDLR	1.340110	2.255281e-116	5.040928e-113
SQLE	1.335197	6.259551e-112	1.199241e-108
DHCR7	1.273321	5.873259e-108	9.845785e-105
FDFT1	1.027726	3.656791e-105	5.449025e-102
TMEM97	1.400237	1.576690e-104	2.114499e-101

Berikut ini adalah top 10 gen yang ekspresinya **turun**.

```
# 3. Lihat top 10 gen turun
top_down <- head(res_df[res_df$direction == "Turun",
                      c("log2FoldChange", "pvalue", "padj")], 10)
print(top_down)
```

	log2FoldChange	pvalue	padj
CDKN2C	-1.026457	8.167276e-61	6.443020e-58
SYK	-1.247685	6.667930e-51	4.258267e-48
JAKMIP1	-1.068715	8.319973e-46	3.984970e-43
C21orf58	-1.093194	4.766030e-41	1.826206e-38
RP11-861A13.4	-1.773645	2.405373e-40	8.718503e-38
HIST1H4C	-3.353461	8.487762e-28	2.231949e-25
C10orf107	-1.196005	4.489134e-26	1.037996e-23
FAM83H	-1.001106	1.283999e-24	2.570106e-22
WDR52	-1.768076	7.717342e-19	8.629469e-17
TMPO-AS1	-1.116153	7.616972e-18	7.566757e-16

Mission 04a: Visualisasi dari ZL0580 dan DMSO

Kita ambil 10 gen yang ekspresinya paling signifikan $\Rightarrow$ padj terkecil.

```
# =====
# Langkah 1: Volcano Plot
# =====
library(dplyr)
library(ggplot2)

# 1. Ambil 10 gen dengan padj terkecil (paling signifikan)
top_genes <- res_df %>%
  filter(!is.na(padj) & padj < 0.05 & abs(log2FoldChange) > 1) %>%
  arrange(padj) %>%
  head(10)

# 2. Tambahkan kolom label (hanya untuk gen top)
res_df$label <- ifelse(rownames(res_df) %in%
  rownames(top_genes), rownames(res_df), "")
```

Kita buat volcano plot-nya.

```
library(ggrepel)

# 3. Buat volcano plot dengan label
volcano_plot_labeled <- ggplot(res_df, aes(x=log2FoldChange, y = -log10(padj),
  color=direction))+
  geom_point(alpha = 0.6, size=1.5) +
  coord_cartesian(ylim = c(0,400)) +
  scale_color_manual(values=c("Naik" = "red", "Turun" = "blue",
```

```

        "Tidak signifikan"="gray" ),
        name="Regulasi") +
geom_vline(xintercept = c(-1,1), linetype="dashed", color="black",
          alpha=0.5) +
geom_hline(yintercept = -log10(0.05), linetype="dashed", color="black",
          alpha=0.5) +
# geom_text(aes(label=label), vjust=-0.5, size=3, check_overlap = TRUE) +
geom_text_repel(aes(label=label), size=3, box.padding = 0.5,
               point.padding = 0.5,max.overlaps = 10) +
labs(
  title = "Volcano Plot: ZL0580 vs DMSO (Top 10 Gen)",
  x = "Log2 Fold Change",
  y = "-Log10 Adjusted P-value"
) +
theme_minimal() +
theme(
  legend.position = "bottom",
  plot.title = element_text(hjust = 0.5, face="bold")
)

```

Kita cetak volcano plot ini.




Figure 1: Volcano Plot mengenai perbandingan ZL0580 dan DMSO (Top 10 Gen)

Berikut adalah informasi mengenai volcano plot di atas.

1. Sumbu X (horizontal) = $\log_2(\text{Fold Change}) \Rightarrow$ seberapa besar perubahan ekspresi gen (naik ke kanan, turun ke kiri).
2. Sumbu Y (vertikal) = $\log_{10} \text{ Adjusted } p\text{-value} \Rightarrow$ seberapa signifikan perubahannya (semakin ke atas, semakin signifikan).
3. Setiap titik adalah satu gen.
 - Titik merah adalah *up-regulated genes*.
 - Titik biru adalah *down-regulated genes*.
 - Titik abu-abu adalah gen yang tidak mengalami perubahan ekspresi.
4. Garis vertikal putus-putus = $\log_2(\text{Fold Change}) = \pm 1$. Batas perubahan minimal ($2\times$ lipat).

5. Garis horizontal putus-putus = $-\log_{10}(0.05)$. Batas signifikansi ($\text{padj} < 0.05$).

Kita simpan plot ini ke suatu file.

```
ggsave("volcano_plot_labeled_ZL0580_vs_DMS0.png", volcano_plot_labeled,  
       width = 10, height = 7, dpi = 300)
```

Terakhir, kita siapkan data dengan mengambil 30 gen yang paling signifikan beserta data ekspresinya.

```
# =====  
# Langkah 2: Heatmap  
# =====  
library(pheatmap)  
library(DESeq2)  
  
# 1. Ambil top 30 gen signifikan (berdasarkan padj)  
res_sorted <- res[order(res$padj),]  
top_genes <- rownames(res_sorted)[!is.na(res_sorted$padj)][1:30]  
  
# 2. Ambil data ekspresi untuk gen-gen tersebut (dari rlog)  
heatmap_data <- assay(rld)[top_genes,]  
  
# 3. Buat annotation untuk sampel (warna berdasarkan kondisi)  
annotation_col <- data.frame(  
  Condition = metadata$condition  
)  
rownames(annotation_col) <- colnames(heatmap_data)
```

Finally, kita plot *heatmap*-nya.




Figure 2: Heatmap dari top 30 gen signifikan terhadap ZL0580/B48, JQ1, dan DMSO

DEG Analysis antara JQ1 dan DMSO

Mari kita hitung berapa jumlah gen yang naik dan turun setelah dikenakan obat **JQ1**.

```
# 1. Membuat object dds
dds <- DESeqDataSetFromMatrix(
  countData = counts_filtered,
  colData = metadata,
  design = ~condition
)

# 2. Jalankan DESeq2
library(DESeq2)
dds <- DESeq(dds)

# 3. Ambil hasil perbandingan
res <- results(dds, contrast = c("condition", "JQ1", "DMSO"))
res <- res[order(res$padj),TRUE]
```



```

# Selanjutnya, kita akan melakukan filter gen
# 1. Ubah data jadi format dataframe
res_df <- as.data.frame(res)

# 2. Tambahkan kolom status signifikansi
res_df$significant <- ifelse(
  !is.na(res_df$padj) &
  res_df$padj < 0.05 &
  abs(res_df$log2FoldChange) > 1,
  "Signifikan",
  "Tidak Signifikan"
)

# 3. Tambahkan kolom arah perubahan
res_df$direction <- ifelse(
  !is.na(res_df$padj) & res_df$padj < 0.05 & res_df$log2FoldChange > 1, "Naik",
  ifelse(
    !is.na(res_df$padj) & res_df$padj < 0.05 & res_df$log2FoldChange < -1,
    "Turun", "Tidak Signifikan"))

# 4. Filter gen signifikan
sig_genes <- res_df[res_df$significant == "Signifikan",]
nrow(sig_genes)

```

```
[1] 2685
```

```

# 5. Lihat gen naik dan turun
table(sig_genes$direction)

```

```

Naik Turun
828  1857

```

Total jumlah gen yang *differently expressed* adalah 2685 yang menunjukkan bahwa JQ1 mempunyai efek yang cukup luas, yaitu sampai menjangkau 2685 gen.

```
828 + 1857
```

```
[1] 2685
```

Kita *export* hasil sebelumnya ke suatu file csv.

```
# 1. Export hasil
write.csv(res_df, "DEG_results_GSE315344_JQ1_vs_DMSO.csv")
```

Berikut ini adalah top 10 gen yang ekspresinya **naik**.

```
# 2. Lihat top 10 gen naik
top_up <- head(res_df[res_df$direction == "Naik",c("log2FoldChange", "pvalue",
                                                    "padj")], 10)
print(top_up)
```

	log2FoldChange	pvalue	padj
H1FO	2.990431	0.000000e+00	0.000000e+00
POLR2A	1.699791	2.441890e-277	2.512247e-274
HEXIM1	2.038436	5.488182e-244	4.301950e-241
NEAT1	2.334043	9.003684e-240	6.443897e-237
H1FX	1.760555	1.221667e-238	8.379106e-236
CIRBP	1.770216	1.161384e-221	7.080568e-219
H3F3B	1.396226	5.366756e-202	2.760693e-199
ADI1	2.218286	4.481090e-199	2.235249e-196
AC093323.3	2.270413	1.222311e-170	3.945189e-168
CALM1	1.481978	7.827099e-156	2.183761e-153

Berikut ini adalah top 10 gen yang ekspresinya **turun**.

```
# 3. Lihat top 10 gen turun
top_down <- head(res_df[res_df$direction == "Turun",
                        c("log2FoldChange", "pvalue", "padj")], 10)
print(top_down)
```

	log2FoldChange	pvalue	padj
ALDH1A2	-5.297466	0	0
CHI3L2	-4.877439	0	0
CD1B	-4.484589	0	0
CD1E	-4.427736	0	0
RLTPR	-3.474330	0	0
MYO1G	-2.979052	0	0
P2RY8	-2.957249	0	0
MYO7B	-2.518866	0	0
ITGA4	-2.438951	0	0
HMGCS1	-2.360647	0	0

Mission 04b: Visualisasi dari JQ1 dan DMSO

Kita ambil 10 gen yang ekspresinya paling signifikan $\Rightarrow$ padj terkecil.

```
# =====  
# Langkah 1: Volcano Plot  
# =====  
library(dplyr)  
library(ggplot2)  
  
# 1. Ambil 10 gen dengan padj terkecil (paling signifikan)  
top_genes <- res_df %>%  
  filter(!is.na(padj) & padj < 0.05 & abs(log2FoldChange) > 1) %>%  
  arrange(padj) %>%  
  head(10)  
  
# 2. Tambahkan kolom label (hanya untuk gen top)  
res_df$label <- ifelse(rownames(res_df) %in%  
  rownames(top_genes), rownames(res_df), "")
```

Kita buat volcano plot-nya.

```
library(ggrepel)  
  
# 3. Buat volcano plot dengan label  
volcano_plot_labeled <- ggplot(res_df, aes(x=log2FoldChange, y = -log10(padj),  
  color=direction))+  
  geom_point(alpha = 0.6, size=1.5) +  
  coord_cartesian(ylim = c(0,800)) +  
  scale_color_manual(values=c("Naik" = "red", "Turun" = "blue",  
    "Tidak signifikan"="gray" ),  
    name="Regulasi") +  
  geom_vline(xintercept = c(-1,1), linetype="dashed", color="black",  
    alpha=0.5) +  
  geom_hline(yintercept = -log10(0.05), linetype="dashed", color="black",  
    alpha=0.5) +  
  # geom_text(aes(label=label), vjust=-0.5, size=3, check_overlap = TRUE) +  
  geom_text_repel(aes(label=label), size=3, box.padding = 0.5,  
    point.padding = 0.5,max.overlaps = 10) +  
  labs(  
    title = "Volcano Plot: JQ1 vs DMSO (Top 10 Gen)",  
    x = "Log2 Fold Change",  
    y = "-Log10 Adjusted P-value"
```

```
) +
theme_minimal() +
theme(
  legend.position = "bottom",
  plot.title = element_text(hjust = 0.5, face="bold")
)
```

Kita cetak volcano plot ini.




Figure 3: Volcano Plot dari JQ1 dan DMSO beserta top 10 gen yang signifikan

Kita simpan plot ini ke suatu file.

```
ggsave("volcano_plot_labeled_JQ1_vs_DMSO.png", volcano_plot_labeled, width = 10,
  height = 7, dpi = 300)
```

Terakhir, kita siapkan data dengan mengambil 30 gen yang paling signifikan beserta data ekspresinya.

```

# =====
# Langkah 2: Heatmap
# =====
library(pheatmap)
library(DESeq2)

# 1. Ambil top 30 gen signifikan (berdasarkan padj)
res_sorted <- res[order(res$padj),]
top_genes <- rownames(res_sorted)[!is.na(res_sorted$padj)][1:30]

# 2. Ambil data ekspresi untuk gen-gen tersebut (dari rlog)
heatmap_data <- assay(rld)[top_genes,]

# 3. Buat annotation untuk sampel (warna berdasarkan kondisi)
annotation_col <- data.frame(
  Condition = metadata$condition
)
rownames(annotation_col) <- colnames(heatmap_data)

```

Finally, kita plot *heatmap*-nya.

```

# 4. Buat heatmap
heatmap_plot <- pheatmap(
  heatmap_data,
  scale = "row",
  main = "Heatmap Top 30 DEG",
  clustering_distance_rows = "correlation",
  clustering_distance_cols = "correlation",
  clustering_method = "complete",
  show_rownames = TRUE,
  show_colnames = TRUE,
  fontsize_row = 6,
  fontsize_col = 8,
  annotation_col = annotation_col,
  color = colorRampPalette(c("blue", "white", "red"))(50),
  border_color = NA
)

```




Figure 4: Heatmap dari top 30 gen signifikan terhadap ZL0580/B48, JQ1, dan DMSO

Discussion

Figure 1 yang merupakan volcano plot untuk ZL0580 dan DMSO. Hal yang menarik adalah 7 dari 10 gen teratas yang berlabel berperan langsung dalam sintesis kolesterol dan lipid lainnya. Selain itu, plot ini menunjukkan bahwa efek utama dari pengobatan dengan ZL0580 adalah penekanan yang signifikan terhadap **jalur biosintesis kolesterol** (Pellaers et al. 2025). Gen-gen yang mengalami regulasi naik seperti HMGCS1, HMGCR, MSMO1, SQLE, DHCR7, FDFT1, dan LDLR semuanya merupakan komponen yang telah dikenal secara luas dalam jalur ini (Chan et al. 2020). HMGCR merupakan enzim pembatas laju yang terkenal dalam sintesis kolesterol dan menjadi sasaran obat-obatan statin.

Hasil ini sangat sesuai dengan mekanisme “*block-and-lock*” yang dimaksudkan pada ZL0580 $\Rightarrow$ penurunan ekspresi yang signifikan pada **jalur biosintesis kolesterol**. Virus, termasuk HIV, diketahui bergantung pada metabolisme lipid sel inang untuk replikasinya. Dengan menekan jalur ini secara signifikan, ZL0580 mungkin menciptakan lingkungan seluler yang tidak hanya diam secara epigenetik tetapi juga tidak menguntungkan secara metabolik bagi reaktivasi dan replikasi HIV. Hal ini menunjukkan mekanisme aksi ganda, yaitu ketika **ZL0580 sekaligus**

mengunci genom virus dalam keadaan diam dan juga membuat virus kekurangan lipid esensial yang diperlukan untuk siklus hidupnya.

Selanjutnya, Figure 3 merupakan volcano plot untuk JQ1 dan DMSO yang menunjukkan pergeseran transkriptomik yang cukup meluas, yaitu sebanyak 2685 gen mengalami perubahan signifikan (828 meningkat, 1857 menurun). Efek ini jauh lebih kuat dibandingkan yang diamati pada ZL0580; hal ini sejalan dengan peran JQ1 sebagai penghambat spektrum luas (*broad-acting inhibitor*) terhadap semua protein BET (Kumar et al. 2026; Pellaers et al. 2025). Lebih spesifik, kehadiran HMGCS1 dalam top 10 gen menegaskan bahwa JQ1 secara drastis menghambat jalur biosintesis kolesterol. Penghambatan metabolisme ini merupakan konsekuensi utama dan langsung dari penghambatan pan-BET, karena virus seperti HIV bergantung pada lipid inang untuk bereplikasi (Tonini et al. 2020).

Table 1: Perbandingan dua analisis DEGs yang sudah dilakukan

Fitur	ZL0580 vs. DMSO	JQ1 vs. DMSO
Total DEGs	297 genes	2685 genes
Up-regulated	63 genes (21%)	828 genes (31%)
Down-regulated	234 genes (79%)	1857 genes (69%)
Effect size	Moderate, targeted	Massive, widespread
Primary action	Selective BRD4 BD1 inhibition	Pan-BET inhibition (BRD2, BRD3, BRD4)
HIV effect	Suppresses HIV (“block and lock”)	Reactivates HIV (“shock and kill”)

ZL0580 merupakan pendekatan yang lebih efektif dalam menekan HIV. ZL0580 secara selektif menargetkan BRD4 BD1 (lihat Table 1) sehingga obat ini menghindari penekanan sistem kekebalan tubuh yang meluas seperti yang terjadi pada JQ1; akibatnya, obat ini berpotensi mengurangi efek samping sekaligus tetap mampu menekan HIV.

Kesimpulan

Analisis ZL0580 dan JQ1 terhadap DMSO menunjukkan pola transkriptomik yang sangat bertolak belakang, yang sejalan dengan efek berlawanan keduanya terhadap transkripsi HIV, yaitu:

1. ZL0580 memicu respons yang terarah dan selektif, terutama dengan menghambat biosintesis kolesterol sekaligus memicu respons stres seluler. Hal ini memperkuat perannya sebagai agen “*block and lock*” dengan efek samping di luar target yang lebih sedikit.

2. JQ1 memicu respons yang luas, menekan fungsi kekebalan, adhesi sel, dan metabolisme. Hal ini menegaskan perannya sebagai agen “*shock and kill*” yang ampuh namun tidak selektif. Maksudnya adalah JQ1 mampu mengaktifkan kembali HIV namun memiliki dampak luas terhadap biologi sel inang.

Jadi **ZL0580** muncul sebagai kandidat terapi yang lebih menjanjikan untuk strategi penyembuhan HIV, karena mampu menekan HIV secara efektif dengan profil transkriptomik yang lebih terfokus dan berpotensi lebih aman dibandingkan dengan JQ1.

Daftar Pustaka

- Chan, She-Hung, Wohn-Jenn Leu, Sharada Prasanna Swain, Jui-Ling Hsu, Duen-Ren Hou, and Jih-Hwa Guh. 2020. “Mechanistic Study of Triazole Based Aminodiol Derivatives in Leukemic Cells—Crosstalk Between Mitochondrial Stress-Involved Apoptosis and Autophagy.” *International Journal of Molecular Sciences* 21 (7): 2470.
- Kumar, Naveen, Zonghui Ma, Fuquan Long, et al. 2026. “Mechanistic Insights and in Vivo HIV Suppression by the BRD4-Targeting Small Molecule ZL0580.” *PLoS Pathogens* 22 (2): e1013449.
- Pellaers, Eline, Julie Janssens, Lore Wils, et al. 2025. “BRD4 Modulator ZL0580 and LEDGINS Additively Block and Lock HIV-1 Transcription.” *Nature Communications* 16 (1): 4226.
- Tonini, Claudia, Mayra Colardo, Barbara Colella, et al. 2020. “Inhibition of Bromodomain and Extraterminal Domain (BET) Proteins by JQ1 Unravels a Novel Epigenetic Modulation to Control Lipid Homeostasis.” *International Journal of Molecular Sciences* 21 (4): 1297.